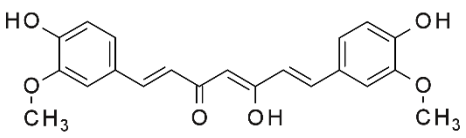
TP 3 : Traitement de fichiers de données avec `Panda`

Ce TP propose d'utiliser le langage de programmation *`Python`* pour traiter des fichiers de données de types .csv. Le TP propose l'utilisation des modules *`matplotlib`* et *`panda`*.

Un grand nombre de fichiers disponibles sur les bases de données sont au format .csv (*Comma Separated Values*), c'est-à-dire des fichiers de valeurs séparées par des virgules. Ces fichiers peuvent être lus directement par `Python` ou via des modules tels que `numpy` ou `pandas`. En pratique, pandas est souvent privilégié, car il permet de structurer le jeu de données en colonnes.

Exercice 1 : Spectre d'absorption de la curcumine

La curcumine est un colorant alimentaire (E100) de couleur jaune et constitue le pigment principal du curcuma (Curcuma longa). Le fichier **curcumine_EtOH.csv**, disponible sur Madoc, contient le spectre de la curcumine dans l'éthanol.



Notes :

……
……
……
……
……
……
……
……
……
……
……
……
……
……
……
……

Utilisation de `pandas` pour créer un DataFrame (structuration des données en colonnes)

L'utilisation de pandas (généralement importé sous l'alias pd) permet d'organiser des jeux de données sous forme de tableaux structurés appelés DataFrames. Ces DataFrames peuvent être créés à partir de fichiers .csv à l'aide de la commande :

```
df = pd.read_csv('chemin_du_fichier.csv', paramètres)
```

Paramètres importants pour la lecture d'un fichier CSV :

`delimiter='...'` : *# spécifie le séparateur des valeurs (utile si ce n'est pas une virgule).*

Par exemple :

```
'\t' # pour une tabulation
';' # pour un point-virgule
```

`usecols=[...]` : *# permet de ne lire que les colonnes spécifiées*

`skiprows=...` : *# indique le nombre de lignes à ignorer au début du fichier*

Lecture et manipulation des données du DataFrame :

`print(df)` : Affiche le tableau généré.

`print(df.columns)` : Affiche le nom des colonnes.

`df['nom_de_la_colonne']` : Sélectionne une colonne entière (utile pour des analyses ou des représentations graphiques).

Exemple d'utilisation pour tracer un graphique avec `matplotlib` :

```
import matplotlib.pyplot as plt
plt.plot(df['nom_de_la_colonne_x'], df['nom_de_la_colonne_y'])
plt.xlabel('Nom de la colonne X')
plt.ylabel('Nom de la colonne Y')
plt.title('Titre du graphique')
plt.show()
```

Instructions :

1. Faire afficher les données présentent dans les fichiers curcumine_EtOH.csv (disponibles sur Madoc) ainsi que le nom des colonnes du `dataframe` ainsi crée.

Notes :

.....

.....

.....

.....

.....

.....

.....

2. Faire la représentation graphique de la longueur d'onde en fonction de l'absorbance.

Utilisation de caractères spéciaux sur *`Matplotlib`*.

`Matplotlib` permet d'afficher des caractères spéciaux dans les légendes et annotations des graphiques, notamment les lettres grecques. Pour cela, il suffit d'encadrer le caractère spécial entre `$` dans une chaîne de texte.

Commande	Caractère	Commande	Caractère	Commande	Caractère
\alpha	α	\eta	η	\pi	π
\beta	β	\theta	θ	\rho	ρ
\gamma	γ	\lambda	λ	\sigma	σ
\delta	δ	\mu	μ	\phi	φ
\epsilon	ε	\nu	ν	\chi	χ
\zeta	ζ	\xi	ξ	\omega	ω

3. Chercher et indiquer sur le graphique par une ligne pointillé la longueur d'onde correspondante au maximum du spectre d'absorption.

Utilisation de *`Pandas`* pour chercher des maximums et minimums.

Comme avec *`numpy`* et les *`ndarray`* il est possible de chercher les extremums dans des *`dataframe`*. Pour cela les commandes *`max`* et *`min`* sont disponibles et la position dans la matrice se trouve à partir de *`idxmax()`* et *`idxmin()`*.

Notes :

……
……
……
……
……
……
……
……
……
……
……
……
……
……
……
……
……
……
……

<u>Exercice 2</u> : Droite d'étalonnage et calcul du coefficient d'absorption molaire de la curcumine

Le fichier **curcumine_concentration.csv**, disponible sur Madoc, contient les valeurs d'absorbance au maximum d'absorption de la curcumine dans l'éthanol à différentes concentrations.

Instructions :

1. Afficher les données présentes dans le fichier *curcumine_concentration.csv* (disponible sur Madoc), ainsi que le nom des colonnes du DataFrame ainsi créé.
2. Représenter graphiquement l'absorbance en fonction de la concentration et éliminer les éventuels points aberrants.
3. Représenter graphiquement l'absorbance en fonction de la concentration et éliminer les éventuels points aberrants.

Suppressions de données dans un *`dataframe`*.

La suppression de données dans un DataFrame se fait à l'aide de la commande :

```
df.drop(nom_de_la_ligne_ou_colonne,  axis=0_ou_1)  # 0 pour indiquer qu'il s'agit d'une ligne ou 1 pour indiquer qu'il s'agit d'une colonne
```

4. Effectuer une régression linéaire et afficher la valeur de la pente ainsi que le coefficient de détermination R^2.

Utilisation de *`linregress`* pour créer un réaliser une regression linéaire.

La commande linregress est disponible dans le module scipy.stats. Elle permet d'effectuer une régression linéaire et renvoie un N-uplet de 6 valeurs :

a : pente (`slope`).

b : ordonnée à l'origine (`intercept`).

c : coefficient de corrélation (`rvalue`), avec c^2 correspondant au coefficient de détermination (R^2).

d : valeur p (`pvalue`).

e : écart-type sur la pente (`stderr`).

f : écart-type sur l'ordonnée à l'origine (`intercept_stderr`).

5. Sachant que la longueur de la cuve est de 1 cm, en déduire la valeur du coefficient d'absorption molaire.

<u>Notes :</u>

……

……

……

……

Exercice : Représentation des spectres de raies de l'hydrogène et de l'hélium

Les fichiers **H41.csv** et **He.csv**, disponibles sur Madoc, indiquent respectivement les valeurs des raies d'absorption de l'hydrogène et de l'hélium.

1. Afficher les données présentes dans les fichiers H41.csv et He.csv ainsi que le nom des colonnes des DataFrames ainsi créés.

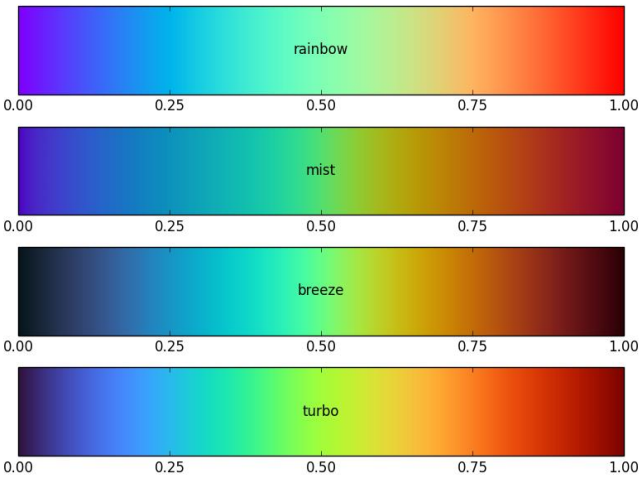
On souhaite maintenant représenter graphiquement ces deux spectres de raies.

La représentation de plusieurs graphiques se fait à l'aide de la commande :

```
plt.subplot(xxx, paramètres_graphiques)
```

- Le premier chiffre indique le nombre total de graphiques à afficher.
- Le deuxième chiffre correspond au nombre de colonnes.
- Le troisième chiffre correspond au numéro du graphique dans l'affichage.

Dans les paramètres graphiques, la commande `facecolor='...'` permet de définir la couleur de fond du graphique. Il est également possible de représenter les raies avec une palette de couleurs. Il existe notamment des palettes adaptées pour afficher les différentes couleurs du spectre visible.



Parmi ces quatre palettes, la colormap 'turbo' est la plus proche du domaine du visible. Lorsque l'on souhaite utiliser une palette de couleurs, il est nécessaire de l'appeler avec la commande :

```
plt.get_cmap('nom_de_la_colormap')
```

Le principe d'une colormap est que la première couleur est associée à la plus faible valeur de la gamme, tandis que la dernière couleur correspond à la valeur la plus élevée. Ainsi, pour attribuer aux longueurs d'onde leurs couleurs dans le domaine du visible, il est nécessaire de :

- Définir la colormap dans les bornes du spectre visible (entre 350 nm et 750 nm).
- Normaliser la longueur d'onde considérée entre 0 et 1, en fonction de sa position dans ce spectre.

2. Représenter les deux spectres de raies l'un en dessous de l'autre, dans le domaine du visible (350 à 750 nm), avec un fond noir et en attribuant à chaque raie sa couleur correspondant au spectre visible.